TRAVAUX A FAIRE DANS LE CADRE DU PROJET BIG DATA

1. Partie Générale : Il s'agit de préparer une présentation générale sur une thématique donnée à partir d'une recherche sur internet en présentant et clarifiant les points suivants :
    1. Pourquoi le recours au Big Data
    2. A quel niveau le Big Data est utilisé
    3. Comment le Big Data a été utilisé
    4. Les différentes étapes à faire

2. Partie Spécifique : Pour votre projet, il faut choisir un ensemble de fichiers de données sur Kaggle ou autres sources à partir desquels il vous est possible de :

    2.1 Proposer une solution Big Data et mettre en œuvre une architecture logicielle formalisant la solution proposée et retrouvée à partir de vos recherches :

    2.2 Sur un plan théorique, la solution architecturale Big Data doit être présentée dans les détails en justifiant le recours à chaque outil.

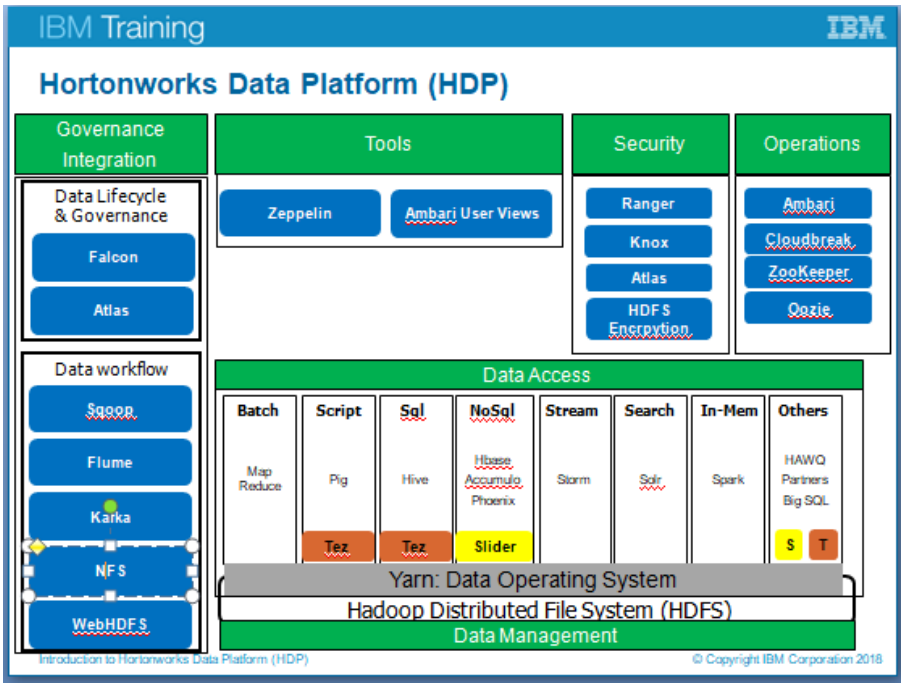
    2.3 Sur un plan expérimental, la solution architecturale Big Data doit comporter entre autres les solutions logicielles citées ci-dessous sachant que je recommande fortement l'utilisation de trois principaux outils à savoir **Kafka** (pour le traitement temps réel), **sqoop** (pour les imports et exports de SGBDR-HDFS et vice versa) et **Flume** (pour le traitement des fichiers Log).

3 Les livrables à remettre

3.1 Une présentation PowerPoint qui
    3.1.1 répond aux questions demandés tout au début de la description du projet,
    3.1.2 présente les trois outils recommandés, leur rôle et leurs étapes d'installation et d'utilisation
    3.1.3 présente le use case traité

3.2 Une démonstration des trois outils installés et fonctionnels

3.3 Une annexe contenant les instructions d'installation et autres informations pouvant mettre en valeur votre contribution.


IBM Training
IBM
Hortonworks Data Platform (HDP)
Governance Integration
Data Lifecycle & Governance
Falcon
Atlas
Data workflow
Sqoop
Flume
Kafka
NFS
WebHDFS
Tools
Zeppelin
Ambari User Views
Security
Ranger
Knox
Atlas
HDFS Encryption
Operations
Ambari
Cloudbreak
ZooKeeper
Oozie
Data Access
Batch
Map Reduce
Script
Pig
Tez
Sql
Hive
Tez
NoSql
Hbase
Accumulo
Phoenix
Slider
Stream
Storm
Search
Solr
In-Mem
Spark
Others
HAWQ
Partners
Big SQL
S
T
Yarn: Data Operating System
Hadoop Distributed File System (HDFS)
Data Management
Introduction to Hortonworks Data Platform (HDP)
© Copyright IBM Corporation 2018